SEMANA 3

14-18 Septiembre (5 días) — *IA Open Source, Despliegue Local y Docker*

Infraestructura disponible a partir de esta semana

A partir de la Semana 3, los estudiantes trabajarán con dos entornos complementarios:

• VM de Azure (proporcionada por Inetum): Máquina virtual con GPU en la nube con modelos grandes desplegados y accesibles a través de una API REST. Permite probar modelos potentes sin limitaciones de hardware local.

• Despliegue local (portátil del estudiante): Instalación de Ollama y despliegue del modelo google/gemma-4-E4B-it (4.5B parámetros efectivos, ~8GB con embeddings). Los estudiantes experimentarán las diferencias entre inferencia local y remota.

DÍA 9 | Lunes 14 de Septiembre

Ecosistema Open Source y Modelos Locales (5h)

Conocimientos Previos Necesarios

→ Conocimientos básicos de Python: pip, entornos virtuales, importación de librerías.

→ Conceptos básicos de hardware: qué es la GPU, RAM, CPU y cómo afectan al rendimiento.

→ Familiaridad con la terminal para ejecutar scripts Python.

Recursos de Autoformación

→ **Curso (EN): Hugging Face NLP Course — incluye traducción parcial al español**
https://huggingface.co/learn/nlp-course/

→ **Modelo: google/gemma-4-E4B-it — Modelo multimodal de Google (texto, imagen, audio)**
https://huggingface.co/google/gemma-4-E4B-it

📖 **Refuerzo Opcional — Cisco Skills for All**

Estos cursos son opcionales y sirven para reforzar los conocimientos base necesarios para la práctica del día.

→ **Data Analytics Essentials — Fundamentos de análisis de datos para entender métricas y benchmarks de modelos**

https://skillsforall.com/course/data-analytics-essentials

→ **Computer Hardware Basics — Entender GPU, RAM, CPU y cómo afectan a la ejecución de modelos IA**

https://skillsforall.com/course/computer-hardware-basics

▸ Autoformación: Hugging Face y Modelos Open Source

- Iniciar el curso de NLP de Hugging Face — completar al menos los módulos introductorios.
- Comprender los conceptos de pesos de modelos, formatos cuantizados (GGUF, GPTQ, Q4, Q8) y requerimientos de VRAM.
- Estudiar la ficha del modelo google/gemma-4-E4B-it en Hugging Face: arquitectura, parámetros efectivos (4.5B), capacidades multimodales (texto, imagen, audio) y licencia Apache 2.0.

▸ Reto del Día

- Crear una cuenta en Hugging Face y explorar el Hub de modelos.
- Buscar y comparar modelos de la familia Gemma 4 disponibles en Hugging Face (E2B, E4B, 12B, 26B-A4B, 31B) según: parámetros efectivos, VRAM requerida, modalidades soportadas y benchmarks.
- Crear una tabla comparativa de al menos 5 modelos open-source (incluyendo Gemma 4, Llama 3, Phi-3, Mistral) con: nombre, parámetros, VRAM necesaria, licencia, idiomas y casos de uso.
- Conectar a la VM de Azure proporcionada por Inetum a través de su API REST y verificar qué modelos están desplegados.
- Ejecutar el mismo prompt en al menos 2 modelos de la VM de Azure y analizar la calidad de las respuestas.

▸ Entregable del Día

- Tabla comparativa de modelos en formato Markdown + script Python de inferencia contra la VM de Azure funcionando.

DÍA 10 | Martes 15 de Septiembre

Despliegue Local: Ollama y Gemma 4 (5h)

Conocimientos Previos Necesarios

→ Haber completado el reto del Día 9 (conexión a la VM de Azure y comparación de modelos).

→ Conocimientos básicos de APIs REST y cómo consumirlas desde Python.

→ Portátil con al menos 8GB de RAM (recomendado 16GB) para despliegue local de modelos.

Recursos de Autoformación

→ **Vídeo (EN): Host ALL your AI Locally — NetworkChuck (YouTube)**
https://www.youtube.com/watch?v=Wjrdr0NU4Sk

→ **Vídeo (ES): ¡EMPIEZA A USAR la IA GRATIS en tu PC! 3 Herramientas — Dot CSV (YouTube)**
https://www.youtube.com/watch?v=Ye7cERMKZDY

▸ Autoformación: Despliegue Local de LLMs

- Ver el vídeo tutorial de Ollama y comprender su arquitectura: servidor local, API REST, gestión de modelos.
- Entender las diferencias entre ejecutar un modelo en local (latencia baja, limitaciones de hardware) vs. en la nube (modelos grandes, dependencia de red).

▸ Reto del Día: Instalación y Despliegue Local

- Instalar Ollama en el portátil siguiendo la documentación oficial (ollama.com).
- Descargar e intentar desplegar el modelo google/gemma-4-E4B-it en local: ollama run gemma4:e4b (o equivalente cuantizado si la RAM es limitada).
- Si el portátil no soporta el modelo E4B, desplegar una versión más ligera: gemma4:e2b o gemma3:4b como alternativa.
- Verificar que el modelo responde correctamente a través de la CLI de Ollama y de la API REST (localhost:11434).

▸ Reto del Día: Chat Local vs. Remoto

- Crear un script Python que se conecte tanto a Ollama local (localhost:11434) como a la API de la VM de Azure.
- Implementar un chat por consola que permita elegir el backend (local o remoto) al iniciar.
- Enviar los mismos 5 prompts a ambos backends y crear una tabla comparativa: calidad de respuesta, tiempo de respuesta, tokens/segundo.
- Documentar las diferencias observadas y reflexionar sobre cuándo usar cada opción (desarrollo vs. producción).

▸ Entregable del Día

- Script de chat dual (local + VM Azure) + informe comparativo de rendimiento y calidad entre despliegue local y remoto.

DÍA 11 | Miércoles 16 de Septiembre

Contenerización Docker (5h)

🎯 Conocimientos Previos Necesarios

→ Haber completado los retos de los Días 9 y 10 (conexión a VM Azure + Ollama local funcionando).

→ Conocimientos básicos de terminal Linux/bash.

→ ASIX: Conocimientos de redes (puertos, protocolos TCP/IP, DNS).

→ DAW/DAM: Conocimientos básicos de cómo funciona un servidor web.

📚 Recursos de Autoformación

→ **Vídeo (ES): Aprende Docker en 14 minutos — Pelado Nerd (YouTube)**
https://www.youtube.com/watch?v=6idFknRlOp4

→ **Vídeo (ES): DOCKER De NOVATO a PRO! Curso Completo — Pelado Nerd (YouTube)**
https://www.youtube.com/watch?v=CV_Uf3Dq-EU

→ **Vídeo (ES): Aprende Docker ahora! Curso completo gratis desde cero — HolaMundo (YouTube)**
https://www.youtube.com/watch?v=4Dko5W96WHg

📖 Refuerzo Opcional — Cisco Skills for All

Estos cursos son opcionales y sirven para reforzar los conocimientos base necesarios para la práctica del día.

→ **Networking Basics — Fundamentos de redes, puertos y protocolos para configurar Docker networking (ASIX)**

https://skillsforall.com/course/networking-basics

→ **Operating Systems Basics — Conceptos de SO, procesos y virtualización relevantes para contenedores**

https://skillsforall.com/course/operating-systems-basics

▸ Reto del Día — Perfiles ASIX lideran

- ASIX: Preparar y explicar a los compañeros los conceptos de Docker: imágenes, contenedores, volúmenes y redes.
- Todos: Instalar Docker Desktop y verificar la instalación (docker run hello-world).
- Escribir un Dockerfile para contenerizar el script de chat del día anterior.
- Crear un fichero docker-compose.yml que levante: un contenedor con Ollama (modelo Gemma 4 E4B precargado) y un contenedor con la API Python (Flask/FastAPI) que pueda conectarse tanto al Ollama local como a la VM de Azure según una variable de entorno.
- ASIX: Configurar las redes Docker, variables de entorno (BACKEND_URL configurable entre local y remoto) y volúmenes persistentes para los modelos descargados.
- DAW/DAM: Añadir un tercer contenedor con un frontend web/móvil que consuma la API.
- Verificar que docker compose up levanta todo el stack correctamente en modo local y que cambiando la variable de entorno se conecta a la VM de Azure.

▸ Entregable del Día

- Repositorio con Dockerfile, docker-compose.yml funcional (con backend configurable local/remoto) y README con instrucciones de despliegue.

DÍA 12 | Jueves 17 de Septiembre

Pruebas de Estrés y Optimización (5h)

🎯 **Conocimientos Previos Necesarios**

→ Haber completado el reto del Día 11 (stack Docker funcional con backend configurable).

→ Conocimientos básicos de programación asíncrona en Python (asyncio) o disposición para aprenderlo.

→ Conceptos básicos de métricas de rendimiento: latencia, throughput, uso de CPU/RAM.

📖 **Refuerzo Opcional — Cisco Skills for All**

Estos cursos son opcionales y sirven para reforzar los conocimientos base necesarios para la práctica del día.

→ **Network Addressing and Basic Troubleshooting — Diagnóstico de red, puertos y resolución de problemas de conectividad**

https://skillsforall.com/course/network-addressing-and-basic-troubleshooting

→ **Network Defense — Estrategias de defensa de red para securizar APIs y servicios expuestos**

https://skillsforall.com/course/network-defense

▸ Reto del Día: Scripts de Carga

- Crear un script Python de pruebas de estrés usando asyncio y aiohttp que envíe peticiones concurrentes.
- Ejecutar las pruebas contra AMBOS backends: Ollama local (Gemma 4 E4B) y la VM de Azure (modelo grande).
- Configurar 3 escenarios de carga para cada backend: 5 usuarios simultáneos, 10 usuarios y 20 usuarios.
- Registrar tiempos de respuesta, errores, tokens/segundo y uso de recursos (CPU, RAM) en cada escenario.
- Crear una tabla comparativa local vs. remoto para cada escenario de carga.

▸ Reto del Día: Optimización

- Identificar cuellos de botella a partir de los resultados: ¿dónde falla primero el modelo local? ¿Y el remoto?
- Implementar al menos 2 optimizaciones: caché de respuestas frecuentes, ajuste de parámetros del modelo (temperatura, max_tokens), cuantización más agresiva del modelo local, o escalado horizontal con Docker replicas.
- Re-ejecutar las pruebas de estrés tras las optimizaciones y comparar resultados antes/después.

▸ Entregable del Día

- Script de pruebas de estrés (local + remoto) + informe comparativo antes/después de optimizaciones con gráficas de rendimiento.

DÍA 13 | Viernes 18 de Septiembre

Retrospectiva Semanal y Presentación — Grupo 3 (5h)

> 🎯 **Conocimientos Previos Necesarios**
>
> → Haber completado los retos de los días anteriores de esta semana.
>
> → Tener preparado un resumen del trabajo individual y de grupo.

▸ Trabajo en Equipo: Recopilación y Análisis (2h)

- Reunirse por grupos y recopilar la experiencia de la semana: qué se ha aprendido, qué herramientas se han usado, qué resultados se han obtenido.
- Analizar los problemas encontrados durante la semana: documentar los bloqueos, errores frecuentes y cómo se resolvieron (o no).
- Identificar los retos no conseguidos y analizar el motivo: falta de tiempo, complejidad técnica, falta de conocimientos previos, problemas de infraestructura, etc.
- Elaborar un documento de retrospectiva del grupo con las secciones: logros, problemas, retos pendientes y lecciones aprendidas.

▸ Preparación de la Presentación (1h)

- Preparar una presentación de 15 minutos que resuma la semana del grupo, centrada en: modelos open source, despliegue local de Gemma 4, Docker, comparativa local vs. VM Azure y pruebas de estrés.
- La presentación debe incluir: demo técnica, problemas encontrados, soluciones aplicadas y reflexión sobre lo aprendido.
- Seleccionar aleatoriamente a la persona que realizará la presentación. Se recomienda usar una herramienta de sorteo como Wheel of Names (wheelofnames.com) o la función random del móvil. Todos los miembros deben estar preparados.

▸ Presentaciones y Debate (1h 15min — 15 min × grupo)

- Grupo 3 lidera la sesión con su presentación de 15 minutos.
- Todos los grupos presentan su retrospectiva semanal.
- Tras cada presentación: ronda de preguntas y feedback constructivo del resto de grupos.
- Al finalizar: reflexión conjunta sobre los temas donde más grupos se han encallado.

▸ Entregable del Día

- Documento de retrospectiva del grupo (Markdown o PDF) subido al repositorio.
- Slides de la presentación compartidas con el resto de la clase.